

Modelo de Dose-Resposta

Adryã e Christian

```
library(tidyverse)
library(MASS)
library(faraway)
library(drc)
library(ggplot2)
library(dplyr)
library(DHARMA)
library(easystats)
library(knitr)

data(earthworms)
dados <- earthworms
```

1 Introdução

A ecotoxicologia depende fortemente de ensaios de dose e resposta para compreender o impacto de substâncias químicas em organismos vivos. Nesses experimentos, busca-se quantificar como a variação na dose (ou concentração) de um estressor químico influencia uma resposta biológica de interesse. Um indicador comportamental comum para avaliar o estresse ambiental em ecossistemas terrestres é a taxa de migração ou fuga de espécies bioindicadoras, como as microcas, quando expostas a solos contaminados.

1.1 Descrição e Origem do Conjunto de Dados

Este trabalho utiliza o conjunto de dados empíricos **earthworms**, disponibilizado no pacote **drc** do ambiente computacional R. Os dados originalmente fornecidos por **Nina Cedergree** (Universidade de Copenhague), consistem em 35 observações provenientes de um teste de toxicidade. O experimento documenta o número de minhocas que permaneceram em um recipiente contaminado com doses variadas de uma substância tóxica não revelada, ou seja,

a quantidade de indivíduos que falhou em migrar para um recipiente vizinho limpo e não contaminado.

1.2 Justificativa

Como o fenômeno estudado avalia a ação individual das minhocas (migrar ou não), mas os dados disponíveis registram a proporção desse comportamento por amostra (o número de indivíduos que permaneceram no solo contaminado em relação ao total exposto a cada dose), trata-se de uma variável resposta de dados agrupados. Essa estrutura empírica motiva a aplicação da teoria de MLG sob a suposição de uma distribuição binomial, o que permite modelar adequadamente a probabilidade de um indivíduo permanecer no recipiente contaminado em função da dose recebida.

2 Metodologia

Detalhamento do tamanho amostral, definição clara da variável resposta e preditores, além da formulação matemática do modelo (função de ligação e componente de variância).

2.1 Variáveis e Distribuição

A amostra do estudo consiste em 35 observações empíricas. A variável resposta é a proporção de minhocas retidas no solo contaminado em cada ensaio, estruturada e modelada como dados agrupados sob a suposição de uma distribuição binomial, $Y_i \sim \text{Binomial}(n_i, p_i)$. A proporção média esperada é $E(Y_i/n_i) = p_i$, assumindo a componente de variância teórica $\text{Var}(Y_i/n_i) = \frac{p_i(1-p_i)}{n_i}$.

Para conectar a probabilidade p_i ao preditor linear η_i , serão ajustadas e comparadas três funções de ligação para dados binomiais:

- **Logito:** $\eta_i = \log\left(\frac{p_i}{1-p_i}\right)$
- **Probit:** $\eta_i = \Phi_{(p_i)}^1$
- **Compementro Log-Log (Cloglog):** $\eta_i = \log(-\log(1 - p_i))$

Em relação aos preditores, a componente sistemática exige atenção especial à dose zero (grupo controle). Como $\log(0)$ é matematicamente indefinido e o comportamento natural sem toxina resulta em uma divisão aproximada de metade das minhocas entre os recipientes, não é apropriado ajustar uma regressão ordinária usando apenas $\log(\text{dose})$. Para contornar isso os preditores foram formulados em segmentos (*pie-wise*) com variáveis indicadoras (*dummy*), isolando o efeito do controle das doses ativas:

$$\eta_i = \beta_0 + \beta_1 I_{\text{controle}} + \beta_2 \log(\text{Dose}_{\text{ativa}})$$

A estimação dos parâmetros será feita pelo método da Máximo Verossimilhança. A seleção do melhor modelo basear-se-á no Critério de Informação de Akaike (AIC), em conjunto com métricas complementares de poder preditivo e explicativo, como Pseudo- R^2 de MacFadden e a Raiz do Erro Quadrático Médio (RMSE). Adicionalmente, a contribuição e significância de cada variável explicativa na componente sistemática será testada através de uma Análise de Desvio (tabela ANOVA) fundamentada na distribuição Qui-Quadrado.

2.2 Modelos Competitivos e Transformação de Variáveis

Para a seleção dos modelos, será apresentado o processo de ajuste, seleção e validação dos Modelos Lineares Generalizados (MLG) aplicados aos dados de dose-resposta com minhocas. Primeiramente, serão ajustados e comparados diferentes modelos, abordando as funções de ligação logito e complemento log-log (cloglog), e devido à natureza dos dados, algumas alterações nestes modelos para validade matemática. Essa escolha e comparação dos modelos tem como base critérios de qualidade global e ajuste, especificamente o Critério de Informação de Akaike (AIC), o Desvio (Deviance), o Pseudo- R^2 de McFadden, a Raiz do Erro Quadrático Médio (RMSE) e a métrica dose efetiva mediana (DE50).

Inicialmente, iremos ajustar os seguintes cinco modelos.

```
mod_cloglog <- glm(cbind(number, total - number) ~ dose,
                  family = binomial(link = "cloglog"), data = earthworms)

modelo_logit1 <- glm(cbind(number, total - number) ~ log(dose + 1), data = earthworms, family = binomial)

modelo_logit2 <- glm(cbind(number, total - number) ~ log(dose + 0.1), data = earthworms, family = binomial)

mod_logit <- glm(cbind(number, total - number) ~ dose,
                family = binomial(link = "logit"), data = earthworms)
dados$controle <- ifelse(dados$dose == 0, 1, 0)
dados$log_dose <- ifelse(dados$dose > 0, log(dados$dose), 0)

mod_glm_dummy <- glm(cbind(number, total - number) ~ controle + log_dose,
                    data = dados,
                    family = binomial(link = "logit"))
```

Que são, respectivamente:

- Modelo Linear Generalizado Binomial com Ligação Complemento Log-Log;
- Modelo Linear Generalizado Binomial com Ligação Logito e variável resposta modificada ($\log + 1$);
- Modelo Linear Generalizado Binomial com Ligação Logito e variável resposta modificada ($\log + 0.1$);
- Modelo Linear Generalizado Binomial com Ligação Logito padrão;
- Modelo Linear Generalizado Binomial com Ligação Logito e variáveis resposta modificadas (adição de variável e modificação);

As variáveis resposta foram modificadas para o logaritmo da dose pois, na biologia, a resposta de um organismo à uma substância quase nunca é linear, o efeito costuma ser em magnitudes (escala logarítmica).

Portanto, se for usado a dose normalmente, o modelo vai dar um peso maior para as doses mais altas, ignorando o que acontece nas doses mais baixas. O log resolve isso espalhando as doses menores e aproximando as maiores, sendo o ideal para o ajuste logístico.

Entretanto, apenas aplicar o logaritmo não seria o suficiente pois, nesta variável explicativa, há a presença de zeros, para contornar isso, foi-se adicionado uma constante ao valor da variável, para um caso foi usado o $\log(\text{dose} + 1)$ e então para minimizar a contribuição da constante foi-se usado o $\log(\text{dose} + 0.1)$, entretanto, essa abordagem gera uma distorção na escala das doses, afetando possíveis estimativas e o cálculo de métricas como a dose efetiva mediana (DE50).

Dessa forma, também para contornar este problema foi-se ajustado um modelo com a adição de uma variável “*dummy*”, isto é, a variável indica se o valor da dose é zero, se for, não aplica o logaritmo, se não for, aplica o logaritmo, ao mesmo tempo evitando que seja feito $\log(0)$ e aplicando o logaritmo importante para o modelo.

2.3 Funções de Ligação e Cálculo da DE_{50}

Agora iremos fazer uma análise da métrica DE50 e seus intervalos de confiança.

A dose efetiva mediana (DE50) é a dose de uma substância que produz um efeito específico em exatamente 50% dos indivíduos testados. Para o nosso contexto, a DE50 é a dosagem exata do contaminante necessária para fazer com que 50% das minhocas migrem.

A definição da DE50 difere para cada função de ligação do modelo. Como aqui estamos tratando modelos com ligação complemento log-log e logito, podemos definir a DE50 como, para o modelo com ligação complemento log-log:

Seja a função de ligação complemento log-log expressa por:

$$\text{cloglog}(p) = \log(-\log(1-p)) = \beta_0 + \beta_1 \cdot X$$

Para definirmos a DE50, substitui-se a probabilidade p por 0,5, tendo:

$$\log(-\log(1-0.5)) = \log(-\log(0.5))$$

Resolvendo, chegamos à conclusão que:

$$\beta_0 + \beta_1 \cdot X_{50} = -0.3665$$

Isolando o X_{50} que representa a DE50, chegamos na conclusão que:

$$DE_{50} = X_{50} = \frac{-0.3665 - \beta_0}{\beta_1}$$

Já para o modelo com ligação logito, temos que:

Seja a função de ligação logito expressa por:

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 \cdot X$$

Substituindo a probabilidade p por 0,5, temos:

$$\log\left(\frac{0.5}{1-0.5}\right) = \log(1) = 0$$

Resolvendo, chegamos à conclusão que:

$$\beta_0 + \beta_1 \cdot X_{50} = 0 \Rightarrow DE_{50} = X_{50} = -\frac{\beta_0}{\beta_1}$$

Mas note que, nos casos em que o logarítmo foi aplicado à dose, a DE_{50} deve ser convertido de volta à escala original usando `exp()` .

2.4 Critérios de Seleção e Diagnóstico

Iremos utilizar 4 critérios para selecionar o modelo ideal:


- Critério de Informação de Akaike (AIC): quanto menor, melhor;
- Desvio (Deviance): quanto menor, melhor;
- Pseudo- R^2 de McFadden: quanto maior, melhor;
- Raiz do Erro Quadrático Médio (RMSE): quanto menor, melhor.

Além destes, há também uma métrica que pode servir como critério, sendo ele a dose efetiva mediana (DE50), neste, iremos observar se o valor é condizente com o contexto, nesse caso, qualquer modelo que apresentar em seu intervalo de confiança valores negativos pode ser considerado inconsistente e descartado, a inconsistência vem de que não existe dose negativa, portanto valores negativos de dose efetiva mediana são inconsistentes.

3 Análise Descritiva

Exploração visual inicial das variáveis explicativas e comportamento empírico da resposta.


```
ggplot(earthworms, aes(x = dose, y = number/total)) +  
  geom_point(color = "darkblue", size = 3, alpha = 0.7) +  
  theme_minimal() +  
  labs(  
    title = "Proporção de Minhocas Retidas vs Dose da Substância Tóxica",  
    x = "Dose",  
    y = "Proporção Empírica (Ficaram/Total)"  
  ) +  
  geom_hline(yintercept = 0.5, linetype = "dashed", color = "red")
```

Excluindo-se o controle e plotando a resposta contra o logaritmo das doses ativas, observamos uma forma sigmoide decrescente. Esse padrão justifica o uso do logaritmo da dose como variável explicativa para as doses ativas.

```
earthworms |>
  filter(dose > 0) |>
  mutate(elogit = log((number + 0.5) / (total - number + 0.5))) %>%
  ggplot(aes(x = log(dose), y = elogit)) +
  geom_point(color = "darkblue", size = 3, alpha = 0.7) +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  theme_minimal() +
  labs(
    title = "Logitos Empíricos vs Log(Dose)",
    x = "Log(Dose) (Excluindo o Controle)",
    y = "Logito Empírico"
  )
```

`geom\_smooth()` using formula = 'y ~ x'



O uso de logitos empíricos plotados contra o logaritmo da dose mostra uma notável tendência linear. A obtenção dessa linearidade é o diagnóstico visual perfeito de que a função de ligação logística (Logito) está corretamente especificada para a componente sistemática do modelo.

4 Ajuste e Diagnóstico do Modelo

Com os modelos definidos, podemos seguir para a comparação e seleção deles.

Com isso definido, iniciaremos pela comparação dos AICs:

```
AIC(mod_cloglog, modelo_logit1, modelo_logit2, mod_logit, mod_glm_dummy)
```

	df	AIC
mod_cloglog	2	91.81223
modelo_logit1	2	80.56107
modelo_logit2	2	77.91139
mod_logit	2	94.19802
mod_glm_dummy	3	78.33592

Para o AIC percebe-se que o modelo logito padrão, complemento log-log e o modelo logito deslocado à 1 unidade apresentam os maiores AICs, o que não é ideal, já aqui pode-se descartar os modelos logito padrão e logito deslocado à 1 unidade, o modelo complemento log-log apesar

de apresentar um AIC alto comparado aos outros não será descartado a fins de comparação de ligações posteriores.

```
df_deviance <- data.frame(
  Modelo = c("Complemento Log-Log", "Logito com log(dose + 0.1)", "Logito com dummy"),
  Desvio = c(deviance(mod_cloglog), deviance(modelo_logit2), deviance(mod_glm_dummy)))

kableExtra::kable(df_deviance,
  booktabs = TRUE,
  digits = 4,
  col.names = c("Modelo", "Desvio Residual"),
  caption = "Comparação da Desvio Residual entre os modelos")
```

Table 1: Comparação da Desvio Residual entre os modelos

Modelo	Desvio Residual
Complemento Log-Log	44.0193
Logito com log(dose + 0.1)	30.1185
Logito com dummy	28.5430

Para a comparação dos desvios dos modelos restantes percebe-se novamente que o modelo complemento log-log apresenta as piores métricas, tendo o maior desvio com uma diferença considerável, enquanto os modelos logito restantes tem uma diferença mínima entre eles.

```
r2_mcfadden_cloglog <- 1 - (summary(mod_cloglog)$deviance / summary(mod_glm_dummy)$null.deviance)

r2_mcfadden_logit2 <- 1 - (summary(modelo_logit2)$deviance / summary(modelo_logit2)$null.deviance)

r2_mcfadden_glm_dummy <- 1 - (summary(mod_glm_dummy)$deviance / summary(modelo_logit2)$null.deviance)

df_r2 <- data.frame(
  Modelo = c("Complemento Log-Log", "Logito com log(dose + 0.1)", "Logito com dummy"),
  `R2 de McFadden` = c(r2_mcfadden_cloglog, r2_mcfadden_logit2, r2_mcfadden_glm_dummy),
  check.names = FALSE
)

kable(df_r2,
  booktabs = TRUE,
  digits = 4,
  caption = "Pseudo-R2 de McFadden para cada modelo ajustado")
```

Table 2: Pseudo-R² de McFadden para cada modelo ajustado

Modelo	R ² de McFadden
Complemento Log-Log	0.5474
Logito com log(dose + 0.1)	0.6903
Logito com dummy	0.7065

No pseudo- R^2 temos mais uma vez uma diferença grande entre o complemento log-log e os logitos, enquanto os logitos, entre si, tem uma diferença marginal. Além disso, no geral podemos afirmar que para qualquer um dos modelos, temos valores ótimos de R^2 , evidenciando a qualidade dos modelos.

```
df_rmse <- data.frame(
  Modelo = c("Complemento Log-Log", "Logito com log(dose + 0.1)", "Logito com dummy"),
  RMSE = c(performance::rmse(mod_cloglog), performance::rmse(modelo_logit2), performance::rmse(modelo_logit1))
)

kable(df_rmse,
      booktabs = TRUE,
      digits = 4,
      col.names = c("Modelo", "RMSE"),
      caption = "Raiz do Erro Quadrático Médio (RMSE) dos modelos")
```

Table 3: Raiz do Erro Quadrático Médio (RMSE) dos modelos

Modelo	RMSE
Complemento Log-Log	0.1238
Logito com log(dose + 0.1)	0.1008
Logito com dummy	0.0968

Já na Raiz do Erro Quadrático Médio (RMSE) temos diferenças marginais entre os modelos, no geral temos bons erros, isto é, mantendo seus valores bem baixos.

```
# Métrica DE50

## Mod_cloglog

res_cloglog <- MASS::dose.p(mod_cloglog, p = 0.5)
de50_cloglog <- as.numeric(res_cloglog)
```

```

se_cloglog <- attr(res_cloglog, "SE")
ic_inf_cloglog <- de50_cloglog - 1.96 * se_cloglog
ic_sup_cloglog <- de50_cloglog + 1.96 * se_cloglog

cat("DE50 (cloglog):", de50_cloglog, "[95% IC:", ic_inf_cloglog, ";", ic_sup_cloglog, "]\n")

```

DE50 (cloglog): -0.1067457 [95% IC: -0.3984615 ; 0.1849701]

```

## modelo_logit2

res_logit2 <- MASS::dose.p(modelo_logit2, p = 0.5)
x50_logit2 <- as.numeric(res_logit2)
se_logit2 <- attr(res_logit2, "SE")

ic_inf_log2 <- x50_logit2 - 1.96 * se_logit2
ic_sup_log2 <- x50_logit2 + 1.96 * se_logit2

# destransforma
de50_logit2 <- exp(x50_logit2) - 0.1
ic_inf_logit2 <- exp(ic_inf_log2) - 0.1
ic_sup_logit2 <- exp(ic_sup_log2) - 0.1

cat("DE50 (logit2):", de50_logit2, "[95% IC:", ic_inf_logit2, ";", ic_sup_logit2, "]\n")

```

DE50 (logit2): 0.07321785 [95% IC: 0.01983951 ; 0.1503717]

```

## mod_glm_dummy

# cf = c(1, 3) pra tirar a variável dummy
res_dummy <- MASS::dose.p(mod_glm_dummy, cf = c(1, 3), p = 0.5)
x50_dummy <- as.numeric(res_dummy)
se_dummy <- attr(res_dummy, "SE")

ic_inf_log_d <- x50_dummy - 1.96 * se_dummy
ic_sup_log_d <- x50_dummy + 1.96 * se_dummy

# destransforma
de50_dummy <- exp(x50_dummy)
ic_inf_dummy <- exp(ic_inf_log_d)
ic_sup_dummy <- exp(ic_sup_log_d)

```

```
cat("DE50 (Dummy):", de50_dummy, "[95% IC:", ic_inf_dummy, ";", ic_sup_dummy, "]\n")
```

```
DE50 (Dummy): 0.1451175 [95% IC: 0.08828153 ; 0.2385447 ]
```

Agora analisando as estimativas, a primeira coisa que pode-se notar é que o modelo com função de ligação complemento log-log resultou em estimativas negativas (tanto a pontual quanto no intervalo de confiança), o que é inconsistente, uma vez que afirma que a dose que afeta exatamente metade dos indivíduos seria uma dose negativa, o que não existe. Permitindo assim que o modelo seja considerado inconsistente e propriamente descartado.

Além disso, os outros dois modelos resultaram em intervalos de confiança consistentes (tudo positivo), portanto, podem ser considerados como válidos.

Entretanto, agora com todas as métricas de comparação apresentadas, iremos prosseguir apenas com o modelo que mais se destacou, isso é, o modelo que apresentou as melhores métricas, mas não só isso, melhor interpretabilidade, portanto, o modelo escolhido será o Modelo Linear Generalizado Binomial com Função de Ligação Logito e Variável Dummy. Pois esse modelo não só apresentou as melhores métricas, como também deve apresentar interpretações bem mais fáceis de se fazer, uma vez que a sua variável explicativa não houve deslocamento como o outro modelo.

4.1 Qualidade de Ajuste

Com o modelo selecionado, iremos verificar a bondade do ajuste pelo desvio (Deviance Goodness-of-Fit), que compara o erro do modelo contra um modelo perfeito (saturado). Podemos tirar conclusão disso a partir de um p-valor, onde quanto maior esse p-valor, melhor está ajustado o modelo.

```
dev_residual <- deviance(mod_glm_dummy)
graus_liberdade <- summary(mod_glm_dummy)$df.residual

# Calcular o p-valor do teste
p_valor_ajuste <- pchisq(dev_residual, graus_liberdade, lower.tail = FALSE)
cat("P-valor da Bondade de Ajuste (Desvio):", p_valor_ajuste, "\n")
```

```
P-valor da Bondade de Ajuste (Desvio): 0.6422658
```

O p-valor resultante é bem alto, confirmando assim que o modelo está bem ajustado aos dados.


4.2 Análise de Resíduos

Para confirmar que o nosso modelo está bem ajustado aos dados, iremos verificar os pressupostos de homogeneidade, pontos influentes, colinearidade e distribuição dos resíduos.

```
check_model(mod_glm_dummy, panel = FALSE) |> plot()
```


Posterior Predictive Check

Model-predicted lines should resemble observed data line




Binned Residuals

Points should be within error bounds




Influential Observations

Points should be inside the contour lines




Collinearity

High collinearity (VIF) may inflate parameter uncertainty



Distribution of Quantile Residuals

Dots should fall along the line



Com a análise apresentada, podemos confirmar que o modelo está ótimo. Na homogeneidade está de acordo com o padrão para modelos binomiais, não há pontos influentes, não há colinearidade e os resíduos seguem a distribuição de referência.

Para fins de maior confirmação, iremos checar a superdispersão dos dados, uma vez que caso haja, a análise de resíduos pode estar apontando falsos positivos.


```
performance::check_overdispersion(mod_glm_dummy)
```

```
# Overdispersion test
```

```
dispersion ratio = 0.977  
p-value = 0.968
```

```
No overdispersion detected.
```

Portanto, é confirmado que não há superdispersão dos dados e a análise de resíduos é válida.

4.3 Variáveis significativas

Para confirmar que a inclusão da variável dummy é significativa ao modelo, iremos realizar uma ANOVA.

```
anova(mod_glm_dummy, test = "Chisq")
```

```
Analysis of Deviance Table
```

```
Model: binomial, link: logit
```

```
Response: cbind(number, total - number)
```

```
Terms added sequentially (first to last)
```

		Df	Deviance	Resid. Df	Resid. Dev	Pr(>Chi)
NULL				34	97.252	
controle	1	28.247		33	69.005	1.068e-07 ***
log_dose	1	40.462		32	28.543	2.005e-10 ***

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Confirmamos assim que todas as variáveis são significativas para o modelo, permitindo que continuemos com esse modelo da forma que está.

5 Interpretação Estatística e Conclusão

Com o modelo devidamente validado, podemos seguir para as interpretações de seus coeficientes e métricas.

É importante ressaltar que há uma variável dummy neste modelo, ela separa quando há dose no solo e quando não há dose no solo, dessa forma, as interpretações podem ser voltadas à presença da dose no solo.

```
broom::tidy(mod_glm_dummy, exponentiate = T)[,1:2]
```

```
# A tibble: 3 x 2
  term      estimate
  <chr>      <dbl>
1 (Intercept) 0.0878
2 controle    17.1
3 log_dose    0.284
```

Com os coeficientes, podemos interpretar que:

- Intercepto: Quando há uma dose no solo, pode-se afirmar que a chance de permanência da minhoca é de menos de 9%, indicando que mesmo em baixas doses, o efeito da dose no solo já é considerável;
- Controle: a chance de uma minhoca ficar no solo controle (sem dose) é 17,08 vezes maior do que a chance de ela ficar no solo com a dose de referência (dose = 1);
- Dose ativa: cada acréscimo em uma unidade no log da dose diminui a chance da minhoca ficar no solo em 71,64%.

Podemos concluir, portanto, que a substância dosada no solo é efetiva no controle da permanência das minhocas no solo, até mesmo em baixas dosagens.

Para concluir, vamos relembrar do `$DE_{50}$`.

```
cat("DE50 (Dummy):", de50_dummy, "[95% IC:", ic_inf_dummy, ";", ic_sup_dummy, "]\n")
```

```
DE50 (Dummy): 0.1451175 [95% IC: 0.08828153 ; 0.2385447 ]
```

Com estes valores de `$DE_{50}$`, podemos afirmar que a dosagem que separa metade das minhocas, isto é, metade das minhocas migram para solo que não está contaminado está, com 95% de confiança, entre 0,0883 e 0,2385.

6 Conclusão

7 Referências